



IAFMNet

Information-Aware Feature Modulation for Efficient Super-Resolution


استاد: دکتر غیاثی راد

درس: تصویرپردازی دیجیتال

ارائه دهنده: محبوبه کریمی

۴۰۴۱۲۶۳۴

Super-Resolution چیست؟



گرفتن عکس کوچک و ساختن عکس بزرگ تر و واضح تر

در مسئله Super-Resolution هدف این است که از یک تصویر با وضوح پایین، تصویری با وضوح بالاتر تولید کنیم، به گونه‌ای که جزئیات تصویر طبیعی و دقیق باقی بمانند.

بیان مسئله


هدررفت منابع



خطار: منابع محاسباتی در حال اتلاف است!

مدل های سنتی، تمام پیکسل ها را یکسان پردازش می کنند. اختصاص توازن پردازشی برابر به یک آسمان صاف و لبه های پیچیده، منجر به اتلاف شدید محاسبات (FLOPs) می شود.

پردازش سنتی (۱۰۰٪ محاسبات)





معرفی مقاله : IAFMNet

هدف اصلی پژوهش

پاسخ علمی به یک پرسش بنیادی در انجام روند SR این است که:

آیا واقعاً همه قسمت‌های تصویر ارزش یکسانی دارند؟

راه حل: تخصیص هوشمند منابع

- ❑ پیکسل‌های مهم لبه‌ها، جزئیات (پردازش بیشتر)
- ❑ پیکسل‌های ساده پس‌زمینه (پردازش کمتر)

نتیجه: کیفیت بالاتر + سرعت بیشتر + مصرف کمتر

سال انتشار: ۲۰۲۶

IAFMNet: Information-Aware Feature Modulation for Efficient Super-Resolution

Junwei Xu, Mengzu Liu, Zhenyu Wang, Fangfang Wu, Sijia Wu, Tao Huang, Weisheng Dong

چالش اصلی این است که افزایش کیفیت تصویر معمولاً به محاسبات بسیار زیادی نیاز دارد. اکثر شبکه‌های عمیق، چه مبتنی بر CNN و چه Transformer، تمام نواحی تصویر را تقریباً به یک اندازه پردازش می‌کنند.


مشکل

- ❑ مدل‌های SR همه پیکسل‌ها را یکسان پردازش می‌کنند.
- ❑ منابع بر روی پیکسل‌های ساده (مثل پس‌زمینه) هدر می‌رود.

[لینک دانلود: Xu IAFMNet Information-Aware Feature Modulation for Efficient Super-Resolution CVPR 2026 paper.pdf](#)



معماری IAFMNet






معماری کلی IAFMNet





استخراج ویژگی : Shallow Feature Extractor



□ تصویر RGB وارد شبکه می شود.

✓ یک کانولوشن ۳ در ۳ انجام می شود تا تصویر از فضای RGB به فضای ویژگی تبدیل شود. تعداد کانال های ویژگی ۲۴ کانال است.

✓ تصویر RGB فقط ۳ عدد برای هر پیکسل دارد. ولی ویژگی های پیچیده تری لازم است: لبه ها، بافت ها، رنگ های نزدیک، الگوها.

• در این مرحله هنوز هیچ پردازش هوشمندی انجام نشده و فقط ویژگی های اولیه استخراج می شوند.

4

3

2

1



تخمین چگالی: Information Density Estimator

IDM: مهم ترین نوآوری مقاله

Information Density Estimator (IDE)


□ بعد از استخراج ویژگی، داده وارد **Information Density Estimator (IDE)** می شود.

✓ این بخش یکی از مهم ترین نوآوری های مقاله است.

وظیفه IDE این است که تشخیص دهد:

- کدام قسمت تصویر اطلاعات زیادی دارد.
- کدام قسمت ساده است.

خروجی این بخش یک **Information Density Map (IDM)** است. این نقشه در ادامه تمام تصمیم های شبکه را هدایت می کند.



4


3

2

1



تخمین چگالی: Information Density Estimator



روند IDE

- در این بخش ابتدا ویژگی‌ها توسط یک لایه کانولوشن و سپس GDN پردازش می‌شوند.
- در ادامه دو پارامتر μ و θ تخمین زده می‌شوند.
- طبق مقاله، نقشه θ پس از آموزش به عنوان Information Density Map مورد استفاده قرار می‌گیرد و در مراحل بعدی شبکه نقش هدایت‌کننده دارد.

4


3

2

1



تخمین چگالی: Information Density Estimator



اگر احتمال وقوع یک ویژگی **پایین** باشد، مقدار منفی لگاریتم احتمال، افزایش پیدا می کند و شبکه **جریمه** بیشتری دریافت می کند. در نتیجه نواحی **غیر قابل پیش بینی** یا دارای اطلاعات زیاد، به عنوان **نواحی مهم** شناسایی می شوند و **Information Density Map** شکل می گیرد.

4


3

2

1



تقویت چگالی: IFEB Blocks (IGRA + ARM)



Information-guided Feature Enhancement Module

- ویژگی‌ها وارد چند **Information-guided Feature Enhancement Block (IFEB)** می‌شوند.
- طبق مقاله، شبکه اصلی شامل ۶ IFEB است.
- هر IFEB دو مسیر موازی دارد:

IGRA ☐

ARM ☐

4


3

2

1



تخصیص منابع هدایت شده: **IGRA**



Information-Guided Resource Allocation

❑ ابتدا IDM نواحی دارای اطلاعات زیاد را مشخص می کند.

❑ سپس با اعمال یک **آستانه**، تنها این نواحی برای انجام محاسبات انتخاب می شوند.

❑ ویژگی های انتخاب شده به صورت **Sparse Tensor** نمایش داده می شوند و عملیات کانولوشن فقط روی همین نقاط انجام می شود.

❑ در مقاله از **Submanifold Sparse Convolution** استفاده شده است که برخلاف کانولوشن معمولی، فقط روی مختصات فعال عملیات انجام

می دهد.

➤ در نتیجه، بدون نیاز به پردازش کل تصویر، محاسبات روی نواحی مهم متمرکز می شود و هزینه محاسباتی کاهش می یابد

4


3

2

1



بازتنظیم تطبیقی : ARM



Affine Recalibration Module

- ❑ برخلاف **IGRA** که تنها روی نواحی منتخب عملیات انجام می‌دهد، **ARM** تمام **Feature Map** را حفظ می‌کند.
- ❑ ابتدا ویژگی‌ها به صورت سراسری خلاصه می‌شوند و سپس با استفاده از IDM پارامترهای **Scale** و **Bias** تولید می‌شوند.
- ❑ در نهایت ویژگی‌های هر کانال با یک تبدیل **Affine** تنظیم می‌شوند.
- ❑ به این ترتیب ویژگی‌های مهم تقویت و ویژگی‌های کم‌اهمیت به صورت نرم تعدیل می‌شوند.
- ❑ وجود هم‌زمان **IGRA** و **ARM** باعث می‌شود هم **هزینه محاسباتی کاهش** یابد و هم **کیفیت بازسازی حفظ** شود.



مقایسه IGRA vs ARM

ویژگی	IGRA (Hard)	ARM (Soft)
پردازش	فقط $k\%$ پیکسل	همه پیکسل‌ها
ماسک	باینری (0/1)	پیوسته (0~1)
سرعت	خیلی سریع	کمی کندتر
دقت	بالا (فقط مهم‌ها)	خوب (همه ولی هوشمند)
منبع	صرفه جویی 95%	صرفه جویی کمتر


4

3

2

1

بازسازی تصویر: PixelShuffle Reconstruction



PixelShuffle Reconstruction

- خروجی آخرین IFEB با نقشه میانگین μ ادغام (Fuse) می شود.
- سپس یک لایه کانولوشن سبک اعمال می شود.
- در نهایت PixelShuffle تصویر HR را بازسازی می کند.

4

3

2

1



ارزیابی تجربی: نتایج کمی

ارزیابی گسترده

مجموعه داده آموزشی: DF2K (DIV2K + Flickr2K)

مجموعه داده تست: Set5، Set14، BSD100، Urban100، Manga109

معیارهای ارزیابی: PSNR، SSIM (روی کانال Y در فضای YCbCr)

Training: Adam، پچ‌های 64×64 ، Data Augmentation، $L=L_1 + \lambda L_{IE}$

مقایسه: با مدل‌های سبک CNN و Transformer بر اساس PSNR، SSIM، Params و FLOPs

نتیجه: دستیابی به تعادل مناسب بین کیفیت بازسازی و کارایی محاسباتی.



ارزیابی تجربی: نتایج کمی

در این جدول چند شاخص مختلف با هم مقایسه شده‌اند:

- تعداد پارامترها (Params)
- هزینه محاسباتی (FLOPs)
- کیفیت بازسازی (PSNR و SSIM)

✓ هدف مقاله فقط افزایش PSNR

نیست؛ بلکه رسیدن به تعادل مناسب

بین کیفیت و هزینه محاسباتی است.

Scale	Methods	Params	FLOPs	Set5	Set14	BSD100	Urban100	Manga109
×2	FSRCNN [8]	12K	6G	37.00/0.9558	32.63/0.9088	31.53/0.8920	29.88/0.9020	36.67/0.9694
	EDSR-baseline [18]	1370K	316G	37.99/0.9604	33.57/0.9175	32.16/0.8994	31.98/0.9272	38.54/0.9769
	CARN-M [1]	415K	91G	37.53/0.9583	33.26/0.9141	31.92/0.8960	31.23/0.9193	-/-
	IMDN [13]	694K	159G	38.00/0.9605	33.63/0.9177	32.19/0.8996	32.17/0.9283	38.88/0.9773
	ShuffleMixer [28]	394K	91G	38.01/0.9606	33.63/0.9180	32.17/0.8995	31.89/0.9257	38.83/0.9774
	LAPAR-A [16]	548K	137G	38.01/0.9605	33.62/0.9183	32.19/0.8999	32.10/0.9283	38.67/0.9772
	SMFANet [38]	186K	41G	38.08/0.9607	33.65/0.9185	32.22/0.9002	32.20/0.9282	39.11/0.9779
	SeemoRe-T [32]	220K	45G	38.06/0.9608	33.65/0.9186	32.23/0.9004	32.22/0.9286	39.01/0.9771
	SAFMN [29]	228K	52G	38.00/0.9605	33.54/0.9177	32.16/0.8995	31.84/0.9256	38.71/0.9771
	IAFMNet(ours)	198K	42G	38.11/0.9611	33.72/0.9190	32.28/0.9006	32.52/0.9312	39.32/0.9792
×3	FSRCNN [8]	12K	5G	33.16/0.9140	29.43/0.8242	28.53/0.7910	26.43/0.8080	30.98/0.9212
	EDSR-baseline [18]	1555K	160G	34.37/0.9270	30.28/0.8417	29.09/0.8052	28.15/0.8527	33.45/0.9439
	CARN-M [1]	415K	46G	33.99/0.9236	30.08/0.8367	28.91/0.8000	27.55/0.8385	-/-
	IMDN [13]	703K	72G	34.36/0.9270	30.32/0.8417	29.09/0.8046	28.17/0.8519	33.61/0.9445
	ShuffleMixer [28]	415K	43G	34.40/0.9272	30.37/0.8423	29.12/0.8051	28.08/0.8498	33.69/0.9448
	LAPAR-A [16]	594K	114G	34.36/0.9267	30.34/0.8412	29.11/0.8054	28.15/0.8523	33.51/0.9441
	SMFANet [38]	191K	19G	34.42/0.9274	30.41/0.8430	29.16/0.8065	28.22/0.8523	33.96/0.9460
	SeemoRe-T [32]	225K	20G	34.46/0.9276	30.44/0.8445	29.15/0.8063	28.27/0.8538	33.92/0.9460
	SAFMN [29]	233K	23G	34.34/0.9267	30.33/0.8418	29.08/0.8048	27.95/0.8474	33.52/0.9437
	IAFMNet(ours)	208K	19G	34.53/0.9281	30.61/0.8454	29.20/0.8068	28.48/0.8561	34.17/0.9476
×4	FSRCNN [8]	12K	5G	30.71/0.8657	27.59/0.7535	26.98/0.7150	24.62/0.7280	27.90/0.8517
	EDSR-baseline [18]	1518K	114G	32.09/0.8938	28.58/0.7813	27.57/0.7357	26.04/0.7849	30.35/0.9067
	CARN-M [1]	415K	33G	31.92/0.8903	28.42/0.7762	27.44/0.7304	25.62/0.7694	-/-
	ShuffleMixer [28]	411K	28G	32.21/0.8953	28.66/0.7827	27.61/0.7366	26.08/0.7835	30.65/0.9093
	LAPAR-A [16]	659K	94G	32.15/0.8944	28.61/0.7818	27.61/0.7366	26.14/0.7871	30.42/0.9074
	SMFANet [38]	197K	11G	32.25/0.8956	28.71/0.7833	27.64/0.7377	26.18/0.7862	30.82/0.9104
	SeemoRe-T [32]	232K	12G	32.31/0.8965	28.72/0.7840	27.65/0.7384	26.23/0.7883	30.82/0.9107
	SAFMN [29]	240K	14G	32.18/0.8948	28.60/0.7813	27.58/0.7359	25.97/0.7809	30.43/0.9063
	SLVR-S [23]	158K	8.5G	32.20/0.8952	28.65/0.7822	27.57/0.7361	26.08/0.7854	30.53/0.9084
	IAFMNet-S(ours)	166K	8.2G	32.24/0.8956	28.68/0.7828	27.61/0.7369	26.15/0.7857	30.71/0.9098
	IAFMNet(ours)	220K	11G	32.37/0.8974	28.80/0.7844	27.68/0.7381	26.39/0.7891	30.97/0.9121


Table 1. Comparison with SOTA lightweight SR methods on public benchmark datasets. Best results are colored with red.



ارزیابی تجربی: نتایج کیفی

اگرچه اختلاف PSNR بین مدل‌ها ممکن است تنها چند صدم دسی‌بل باشد، اما از **نظر بصری** تفاوت‌ها کاملاً قابل مشاهده هستند.

در تصاویر دارای الگوهای تکرارشونده، خطوط منظم و بافت‌های پیچیده، IAFMNet توانسته جزئیات بیشتری را حفظ کند.





Ablation Study

بررسی IGRA

حذف IGRA

وقتی IGRA حذف می‌شود:

- هزینه محاسباتی افزایش پیدا می‌کند و بخشی از مزیت روش از بین می‌رود.

بررسی ARM

حذف ARM

وقتی ARM حذف می‌شود:

- کیفیت بازسازی کاهش پیدا می‌کند.
- این نشان می‌دهد ARM واقعاً مؤثر است.

بررسی آستانه (Threshold)

در مقاله چند مقدار مختلف بررسی شده است:

- ۵٪
- ۱۰٪
- ۲۰٪
- ۵۰٪

نتیجه مقاله این است که:

- آستانه ۵٪ بهترین تعادل بین کیفیت بازسازی و هزینه محاسباتی را ایجاد کرده است.



جمع‌بندی

نتایج تجربی نیز نشان می‌دهد که

این راهکار توانسته با تعداد پارامتر و هزینه

محاسباتی کمتر، عملکردی رقابتی و در

برخی موارد بهتر از روش‌های مرجع ارائه

دهد.

این نقشه در دو بخش مختلف شبکه

استفاده می‌شود:

در IGRA

برای انتخاب نواحی مهم جهت انجام

کانولوشن اسپارس و

در ARM

برای تعدیل تطبیقی ویژگی‌ها.

می‌توان به جای افزایش مداوم اندازه شبکه،

از اطلاعات موجود در تصویر برای تخصیص

هوشمند منابع محاسباتی استفاده کرد.

نوآوری اصلی مقاله تولید یک **Information**

Density Map به صورت بدون نظارت است

که مشخص می‌کند کدام نواحی تصویر

اطلاعات بیشتری دارند.



با تشکر از توجه شما

پرسش و پاسخ